

# UNIVERSIDADE FEDERAL RURAL DA AMAZÔNIA

## TÓPICOS ESPECIAIS EM INTELIGÊNCIA ARTIFICIAL (2020.2)

### RESENHA CRÍTICA:

#### COVID-Classifier: an automated machine learning model to assist in the diagnosis of COVID-19 infection in chest X-ray images - scientific reports

Autor: Zaú Júlio A. Galvão

O artigo em questão trata do desenvolvimento de um sistema utilizando aprendizado de máquina para pacientes não COVID-19 em/com contraste a pacientes com pneumonia, através de imagens CXR (chest x-ray - radiografia de tórax). O sistema foi construído a partir da redução de dimensionalidade de imagens CXR para extração de *features* informacionalmente densas. A implementação do classificador, considerada um sucesso, é proposta para triagem hospitalar inicial de casos não COVID-19. Os autores propõem o uso dessa modalidade de imagens devido ao baixo custo, rápida produção e análise, em casos como Itália e Reino Unido, onde os recursos foram bem alocados fazendo desta. Entretanto, é conhecida a dificuldade na interpretação humana destas imagens, devida sua semelhança com diversas outras enfermidades, como gripe comum (Influenza), dentre outras. Uma breve análise do histórico de utilização de algoritmos de aprendizado de máquina (ML), demonstra sucesso, precisão relativamente alta, na maioria do vasto campo de aplicabilidade desta técnica, por este motivo a premissa do trabalho é positiva e, no contexto em que se encontra, de importância inquestionável. Mediante estas considerações, os autores trataram o sistema hipotético de forma que, na hipótese em questão, a avaliação do contraste de imagens CXR utilizando ML, era viável e que às abordagens empregadas já distinguiam um “norte” a validação do trabalho, o que, no entanto, não descaracteriza o sistema como “state-of-the-art”, em suma.

O desenvolvimento do sistema a partir da extração de características “sintéticas”, providas da redução de dimensionalidade de imagens CXR não segmentadas, segundo os autores, resultou em uma máquina com capacidade de distinção (Classificação) com precisão de 94%. Esta técnica já é conhecida e amplamente aplicada em diversas aplicações de ML. Ela busca criar uma nova *feature* (característica ou recurso), correlacionada a original, em dimensões inferiores, buscando a otimização do espaço amostral, que é repassada de alguma forma para a resposta de saída dos algoritmos, e ou, influenciando o processo de treinamento destes algoritmos, a partir do *trade-off* **Informação por recurso X Número de recursos**. Embora o número de recursos seja consideravelmente baixo para este tipo de aplicação, a geração de amostras a partir da sintetização foi aplicada, resolvendo parcialmente a questão. A partir disso, foi realizado o estudo da relação entre o número de *features* e o espaço amostral, através do coeficiente de Pearson foi encontrado 73% de correção entre as amostras do conjunto. O emprego de PCA (Principal Component Analysis), foi realizado para reduzir o espaço amostral em 64 elementos sintéticos dentro espaço amostral, condensando a informação dos exemplos prévios. Considerando o número de amostras originais e a geração de novas amostras, a premissa da combinação componente-correlação foi positivamente empregada na preservação da informação.

O sistema final utiliza um classificador baseado em *multilayer perceptron* (MLP), que, a partir dos hiperparâmetros forneceu ao sistema a acurácia necessária para a avaliação do modelo. A precisão apurada com o modelo, demonstra que a performance e precisão para a aplicabilidade proposta no início do artigo é atendida, de forma que o sistema torna-se plenamente empregável.